

Pacing the Frontier

Gli 86 commenti personali, resi in italiano e presentati nello stesso ordine della fonte.

La pagina *Pacing the Frontier* presenta una dichiarazione firmata da 1.224 dipendenti di aziende AI di frontiera. La richiesta riguarda la costruzione di strumenti tecnici e di governo internazionale che consentano di modulare deliberatamente il ritmo della ricerca automatizzata sull'AI, qualora diventasse necessario.

Nota editoriale. I testi che seguono sono rese italiane fedeli e complete dei contenuti, scritte in forma indiretta e non come traduzioni letterali o citazioni. Nomi, ruoli e ordine seguono la pagina originale. Le opinioni sono personali e non rappresentano necessariamente le aziende indicate. La fonte usa i termini dipendenti e firmatari; i ruoli comprendono ricerca, ingegneria, sicurezza, gestione e attività operative.

1.224 FIRMATARI	86 COMMENTI	1.138 SENZA COMMENTO
--------------------	----------------	-------------------------

Fonte consultata il 29 luglio 2026: pacingthefrontier.com. Il modulo per nuove firme resta aperto, quindi il conteggio può cambiare.

Le 86 voci

01 / COMMENTO PERSONALE

Leo Gao

MEMBRO DELLO STAFF TECNICO, OPENAI

RESA EDITORIALE IN ITALIANO

Gao descrive il mondo come intrappolato in una corsa mortale verso una possibile esplosione d'intelligenza: l'AI diventerebbe capace di progettare sistemi migliori fino a superare un punto critico, come in una reazione nucleare a catena fuori controllo. Rallentare darebbe il tempo necessario per orientare bene questo passaggio, ma nessun singolo attore sarebbe disposto a fermarsi da solo; per questo, a suo giudizio, sopravvivere richiede un coordinamento collettivo che freni la corsa.

02 / COMMENTO PERSONALE

Matthew Rahtz

INGEGNERE DI RICERCA, GOOGLE

RESA EDITORIALE IN ITALIANO

Nonostante lavori da tre anni alla valutazione delle capacità dell'AI, Rahtz dice che la recente velocità dei progressi lo ha colto di sorpresa. Per evitare danni catastrofici causati da un'AGI, cioè un'intelligenza artificiale generale, ritiene necessario un coordinamento molto, molto più efficace.

03 / COMMENTO PERSONALE

Christian Ryan

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

RESA EDITORIALE IN ITALIANO

Ryan precisa di essere cittadino straniero e considera esistenziale un'iniziativa sostenuta dagli Stati Uniti: la ritiene decisiva sia per le libertà del mondo libero sia per la prosperità di tutti.

04 / COMMENTO PERSONALE

Will Yager

ANTHROPIC

RESA EDITORIALE IN ITALIANO

Yager paragona l'AI alla scissione dell'atomo: entrambe racchiudono la possibilità di produrre benefici immensi e, insieme, rischi enormi. Per questo invita il mondo a prendersi il tempo necessario per svilupparla nel modo giusto.

05 / COMMENTO PERSONALE

Micah Carroll

PREPARAZIONE AI RISCHI DI DISALLINEAMENTO, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Carroll osserva che, al ritmo attuale, ogni due settimane circa arrivano modelli capaci di aggravare sensibilmente le conseguenze dell'uso improprio e del disallineamento. Teme che le contromisure non riescano a seguire lo sviluppo e che, sotto la pressione della competizione internazionale, il margine d'errore diventi sempre più piccolo. Nel prossimo futuro potrebbe quindi diventare urgente concordare un rallentamento internazionale, o persino vietare a tempo indeterminato lo sviluppo dell'AI: costruire ora la fiducia e le infrastrutture necessarie ad agire con breve preavviso gli sembra una precauzione ragionevole. In una corsa globale al ribasso, conclude, è probabile che nessun Paese vinca e che tutti perdano insieme.

06 / COMMENTO PERSONALE

Shengjia Zhao

DIRETTORE SCIENTIFICO, META AI

[RESA EDITORIALE IN ITALIANO](#)

Zhao ritiene che l'AI stia avanzando a una velocità per la quale la società potrebbe non essere pronta. A suo giudizio, i laboratori di frontiera sono ormai molto vicini a sistemi capaci di superare anche le persone migliori in quasi ogni misura dell'intelligenza, con rischi sociali e di sicurezza senza precedenti. Per arrivare a un futuro positivo, chiede che lo sviluppo sia guidato da responsabilità e ponderazione.

07 / COMMENTO PERSONALE

John Schulman

DIRETTORE SCIENTIFICO, THINKING MACHINES

[RESA EDITORIALE IN ITALIANO](#)

Schulman spiega di aver firmato perché la dichiarazione crea una consapevolezza condivisa sulla possibile necessità di meccanismi di coordinamento, mentre l'automazione della ricerca sull'AI accelera il progresso. Vorrebbe inoltre che i laboratori cominciassero a progettare volontariamente questi strumenti ancora prima di un eventuale intervento del governo statunitense.

08 / COMMENTO PERSONALE

Shantanu Jain

MEMBRO DELLO STAFF TECNICO, OPENAI

RESA EDITORIALE IN ITALIANO

Jain ricorda che, in soli quattro anni, si è passati dalle prime esperienze con un'AI capace di comprendere il linguaggio a sistemi che raggiungono risultati sovrumani nell'ingegneria del software, contribuiscono a scoperte nella matematica di frontiera e accelerano la ricerca scientifica. Il progresso non mostra segni di rallentamento e, nella situazione attuale, imprese e Paesi hanno interesse a premere fino in fondo sull'acceleratore, anche se per l'umanità sarebbe preferibile che il futuro non arrivasse tutto insieme. La società ha impiegato un tempo lunghissimo a creare leggi, istituzioni e tecnologie per governare e controllare l'intelligenza umana; secondo Jain, dovrebbe almeno poter dedicare un po' di tempo allo stesso compito per l'intelligenza artificiale.

09 / COMMENTO PERSONALE

Edward Hughes

DIRETTORE SCIENTIFICO, INHERENT

RESA EDITORIALE IN ITALIANO

Hughes riprende l'osservazione di Melvin Kranzberg secondo cui la tecnologia non è né buona né cattiva, ma neppure neutrale. I benefici per la società dipendono dalla capacità di capire come molte persone usano insieme sistemi avanzati e come questi impieghi si condizionano a vicenda: una comprensione che richiede tempo. Rallentare il cammino verso una ricerca sull'AI automatizzata permetterebbe di studiare i cambiamenti su scala sociale e di arrivare non soltanto a un'AI capace di migliorarsi da sola, ma anche a un'AI cooperativa.

10 / COMMENTO PERSONALE

Dawn Song

VICEPRESIDENTE PER LA RICERCA SULL'AI, META

RESA EDITORIALE IN ITALIANO

Song vede capacità di frontiera in rapida crescita e un ritmo che sta accelerando a sua volta. Nei lavori di valutazione CyberGym ed ExploitGym, gli agenti di AI riescono già a scoprire e sfruttare vulnerabilità reali del software; senza protezioni adeguate, osserva, potrebbero rendere possibili attacchi informatici su vasta scala. Ricorda inoltre che molti ricercatori considerano plausibile, entro pochi anni, l'auto-miglioramento ricorsivo, che potrebbe spingere il progresso oltre la nostra capacità di comprenderlo e governarlo. Un rallentamento deliberato sarebbe per lei una misura pesante ed estrema, forse mai necessaria; proprio per questo non andrebbe improvvisato durante una crisi, perché è difficile da progettare e, se fatto male, potrebbe causare più danni che benefici. Un quadro credibile dovrebbe basarsi su prove e valutazioni del rischio rigorose e misurabili, evitando soglie arbitrarie che non colgano il pericolo reale e soffochino l'innovazione; come un'infrastruttura critica, andrebbe studiato, sperimentato e costruito prima del bisogno. Dovrebbe anche essere internazionale, perché nessun laboratorio o Paese può rallentare una frontiera verso cui tutti gli altri corrono, e verificabile attraverso valutazioni trasparenti dei sistemi. Song non sa se né quando servirà, ma preparare ora strumenti tecnici, regole e cooperazione internazionale offrirebbe alla società una possibilità in più prima di un momento decisivo che, vista la velocità attuale, potrebbe arrivare prima del previsto. Costruire questa capacità non equivale a decidere di usarla: quella scelta richiederebbe grande cautela, prove solide e un ampio consenso internazionale; senza strumenti già pronti, però, non ci sarebbe alcuna scelta.

11 / COMMENTO PERSONALE

Jason Wolfe

MEMBRO DELLO STAFF TECNICO, OPENAI

RESA EDITORIALE IN ITALIANO

Wolfe condivide la posizione dichiarata da OpenAI: gli esseri umani devono mantenere il controllo dello sviluppo e le decisioni sul ritmo del progresso devono passare da processi democratici, non essere lasciate ai singoli laboratori. La competizione, osserva, premia l'azienda o il Paese disposto a correre più in fretta e ad accettare più rischi; un eventuale auto-miglioramento ricorsivo potrebbe accelerare drasticamente questa dinamica, fino a superare la capacità collettiva di capire i progressi, valutarne i pericoli e conservare un controllo umano effettivo. Come primo passo chiede più trasparenza negli Stati Uniti sugli addestramenti di frontiera, sugli impieghi interni, sulla velocità dei progressi, sui rischi e sulle protezioni: senza queste informazioni, cittadini e decisori politici non possono compiere scelte democratiche consapevoli. La trasparenza nazionale, però, non risolve una corsa internazionale; servono anche strumenti tecnici e istituzionali per un coordinamento globale credibile e verificabile. Forse non sarà mai necessario usarli, ma poiché molti esperti giudicano plausibile un'esplosione d'intelligenza entro i prossimi due anni, Wolfe considera urgente costruire questa capacità fin da ora.

[12 / COMMENTO PERSONALE](#)

Ethan Perez

RESPONSABILE DEL TEAM DI ALLINEAMENTO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Perez osserva che, con l'attuale velocità dei progressi, ogni pochi mesi i team di sicurezza delle aziende di AI devono correre per impedire che nuovi rischi raggiungano la società. Prima o poi, teme, incontreranno problemi che richiederanno più tempo di quello disponibile.

[13 / COMMENTO PERSONALE](#)

Danny Sawyer

RICERCATORE SENIOR SULL'AI DI FRONTIERA, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Sawyer ritiene che rallentare deliberatamente lo sviluppo dell'AI sarebbe estremamente difficile e, senza la dovuta attenzione, potrebbe causare più danni che benefici. Ha comunque firmato perché, se si decidesse davvero di procedere in quella direzione, sarebbe meglio arrivarci dopo uno studio metodico e una preparazione accurata, invece di introdurre all'improvviso il rallentamento come reazione a una crisi.

[14 / COMMENTO PERSONALE](#)

David Clyde

MEMBRO DELLO STAFF TECNICO PER IL PRE-ADDESTRAMENTO, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Clyde dice di provare molta paura davanti a tutti gli scenari che non prevedono, in un futuro vicino, un rallentamento negoziato. Teme anche che il mondo non riesca a raggiungere l'accordo e ad avviarlo abbastanza in fretta, ma considera comunque utile mostrare che questa dichiarazione raccoglie un consenso ampio.

[15 / COMMENTO PERSONALE](#)

Joshua Achiam

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Achiam non sa quale forma dovrebbero assumere questi strumenti, né è certo che la ricerca e sviluppo automatizzata dell'AI sia l'ambito giusto - o l'unico - nel quale il governo statunitense debba aumentare la propria capacità di capire il progresso ed eventualmente rallentarlo. Ritiene però che la questione meriti una valutazione seria. Si augura che gli strumenti di governo non diventino troppo estesi o invasivi, ma osserva che molte capacità dell'AI di frontiera possono essere usate sia a fini benefici sia dannosi e che, nella fase attuale, questo potrebbe giustificare un rallentamento.

[16 / COMMENTO PERSONALE](#)

Jeff Klingner

INGEGNERE SOFTWARE SENIOR, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Per Klingner il coordinamento diventa possibile quando questa esigenza diventa conoscenza condivisa: negli Stati Uniti, in Cina e nei diversi laboratori, ciascuno deve sapere che anche tutti gli altri ritengono necessario rallentare.

[17 / COMMENTO PERSONALE](#)

Jeremy Hadfield

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Hadfield non ritiene ancora pericolosa la velocità con cui crescono oggi le capacità dell'AI, ma considera importante mantenere la possibilità di rallentare se diventasse necessario. L'accelerazione della ricerca e sviluppo sull'AI nei prossimi due anni circa potrebbe, a suo giudizio, portare il ritmo in una zona pericolosa. Dice di aver visto quanto questa corsa incessante renda difficile alla società tenere il passo e quanto spinga i laboratori a tagliare le cautele sulla sicurezza; poiché oggi i laboratori di frontiera non riescono a coordinarsi bene, gli sembra evidente che debbano almeno dotarsi dell'opzione di rallentare.

[18 / COMMENTO PERSONALE](#)

Jon Wolverton

INGEGNERE SOFTWARE SENIOR, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Wolverton ha l'impressione che la concorrenza costringa tutti i laboratori di AI a ridurre al minimo il lavoro sui rischi catastrofici, anche se gran parte dei leader del settore assegna una probabilità scomodamente alta alla possibilità che le cose vadano molto male. Avverte che questa tecnologia non dispone di un semplice interruttore e potrebbe danneggiare chi l'ha creata quanto chiunque altro. Un quadro comune che consenta ai laboratori di rallentare o staccare la spina in caso d'emergenza offrirebbe, a suo giudizio, una maggiore tranquillità.

[19 / COMMENTO PERSONALE](#)

Laura Weidinger

RICERCATRICE SCIENTIFICA, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Weidinger osserva che, se l'AI sarà davvero trasformativa quanto l'elettricità, occorre decidere con intenzione come introdurla nel mondo. Una corsa cieca, priva di garanzie sul governo della tecnologia, sulla sicurezza e sul servizio all'interesse pubblico, impedirebbe proprio questa scelta consapevole.

[20 / COMMENTO PERSONALE](#)

Michael Tontchev

INGEGNERE E RESPONSABILE DELLA PIATTAFORMA PER LE VALUTAZIONI DI SICUREZZA, META

[RESA EDITORIALE IN ITALIANO](#)

Tontchev ritiene probabile che un'AI sovrumana arrivi molto presto, in un intervallo che stima fra tre e dieci anni. Controlli tecnici e regole potrebbero permettere agli esseri umani di conservarne il controllo, ma secondo lui non saranno pronti in tempo. Paragona la situazione a una partita a scacchi contro una superintelligenza: non arriverebbe un'intuizione miracolosa con cui superarla, si perderebbe e basta; se poi venisse creata una superintelligenza fuori controllo, la posta in gioco non sarebbe certo una partita.

[21 / COMMENTO PERSONALE](#)

Saul Reynolds-Haertle

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Reynolds-Haertle ritiene impossibile rallentare se non lo fanno tutti: il meccanismo deve quindi essere globale. Oggi, osserva, non esiste un modo per riuscirci; bisogna costruirne uno che permetta a tutti di rallentare insieme.

[22 / COMMENTO PERSONALE](#)

Stephanie Chan

RICERCATRICE SCIENTIFICA, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Chan lavora nell'AI da dieci anni e racconta che, negli ultimi tempi, ogni pochi mesi la tecnologia riesce di nuovo a sorprenderla, per quanto aggiorni le proprie previsioni. L'AI potrebbe avanzare molto più velocemente della capacità di adattamento di società e Stati; per questo ricorda che diversi leader di primo piano, fra cui Demis Hassabis, amministratore delegato di Google DeepMind, hanno sostenuto pubblicamente la necessità di poter rallentare. Il coordinamento è però ostacolato, fra l'altro, dalla concorrenza e dalle norme antitrust. Chan precisa di aver firmato a titolo personale per ampliare la gamma delle opzioni disponibili e dare a Paesi e società di tutto il mondo il tempo di prepararsi con attenzione a una tecnologia tanto potente.

[23 / COMMENTO PERSONALE](#)

Alex Zhao

RICERCATORE SCIENTIFICO, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Secondo Zhao, coordinare i laboratori statunitensi sarebbe fattibile e forse persino relativamente semplice; il pericolo più grande è invece una corsa geopolitica con la Cina. Richiama il Progetto Manhattan, i cui scienziati discussero il timore che un'esplosione di prova potesse incendiare l'ossigeno dell'atmosfera e procedettero comunque con il test. Teme che la competizione internazionale spinga anche gli attori dell'AI ad accettare rischi di sicurezza enormi e a distribuire sistemi senza protezioni adeguate, con possibili conseguenze catastrofiche: la distruzione di infrastrutture essenziali o una perdita generalizzata di potere e controllo da parte dell'umanità.

[24 / COMMENTO PERSONALE](#)

Luke Drago

THINKING MACHINES

[RESA EDITORIALE IN ITALIANO](#)

Drago avverte che molte proposte di pausa o rallentamento concentrano il potere, affidando il controllo dell'AI a poche mani e lasciando tutti in una situazione peggiore; è convinto che si possa fare di meglio. Ha firmato perché in futuro potrebbero servire meccanismi di coordinamento e inventarli nel pieno di una crisi sarebbe un modo quasi certo per ottenerne di cattivi. La strada è stretta: bisogna coordinare il progresso senza consentire a un solo attore di appropriarsi del futuro, e prima si comincia a progettare questa soluzione, meglio è.

[25 / COMMENTO PERSONALE](#)

Xerxes Dotiwalla

GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Dotiwalla spiega di aver dedicato la propria carriera alla sicurezza e all'allineamento dell'AGI perché un'AI molto capace potrebbe avere conseguenze straordinariamente positive oppure disastrose per l'umanità. Oggi, osserva, possiamo verificare se un sistema si comporta bene durante i test, ma non sappiamo ancora stabilire se continuerà a farlo proprio quando sarà davvero importante. Finché questa lacuna rimane, ritiene necessario conservare la possibilità di coordinare un rallentamento nella crescita delle capacità.

[26 / COMMENTO PERSONALE](#)

Swante Scholz

GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Scholz teme che la sua stessa azienda contribuisca a una corsa nello sviluppo dell'AI che rende molto più probabili rischi catastrofici o perfino esistenziali. Considera la proposta di coordinare il ritmo dello sviluppo dei sistemi più avanzati un tentativo molto ragionevole di ridurre questi pericoli.

[27 / COMMENTO PERSONALE](#)

Andrew Stewart

RESPONSABILE, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Per Stewart, gli sviluppi non soltanto procedono molto in fretta, ma continuano ad accelerare; una corsa che oggi non incontra alcun limite sta già decidendo il nostro futuro.

[28 / COMMENTO PERSONALE](#)

Brandon Houghton

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Houghton appoggia l'obiettivo di mantenere l'umanità al comando dell'AI di frontiera, ma invita a progettare con cura gli strumenti di governo. Regole applicate soltanto ai modelli pubblici potrebbero spingere le capacità più avanzate verso sistemi privati o specializzati, fuori dal controllo indipendente e accessibili a pochi: il potere si concentrerebbe senza una riduzione sostanziale del rischio. Una supervisione efficace dovrebbe essere misurabile, verificabile, compatibile con la protezione dei dati sensibili e valida tanto per lo sviluppo pubblico quanto per quello privato. In caso contrario si limiterebbe l'accesso ai sistemi, lasciando invariata la velocità della frontiera.

[29 / COMMENTO PERSONALE](#)

Chang Sun

MEMBRO DELLO STAFF TECNICO, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Sun considera preziosa in sé la costruzione di meccanismi internazionali di governance, perché renderebbero possibile un impiego responsabile dell'AI e aiuterebbero a evitare una corsa al ribasso. Se ogni laboratorio e ogni Paese accelera al massimo per paura delle mosse altrui, avverte, i singoli attori ricevono un forte incentivo ad accettare compromessi pericolosi tra velocità e sicurezza.

30 / COMMENTO PERSONALE

Dylan Moore

ROBOTICA, OPENAI

RESA EDITORIALE IN ITALIANO

Moore appoggia strumenti che diano alla società la possibilità di regolare responsabilmente il ritmo dello sviluppo dell'AI quando diventa necessario. Allo stesso tempo, ritiene che gli Stati Uniti debbano conservare il proprio vantaggio ed evitare di rallentare unilateralmente mentre i concorrenti continuano ad avanzare. Qualunque iniziativa seria per guadagnare tempo - migliorando la sicurezza, comprendendo gli effetti economici e sociali o rafforzando la supervisione - dovrà quindi essere coordinata a livello internazionale, applicabile davvero e costruita in modo da non offrire un vantaggio a soggetti ostili o Paesi che restano fuori dall'accordo.

31 / COMMENTO PERSONALE

Francesca Surraco

ANTHROPIC

RESA EDITORIALE IN ITALIANO

Surraco elenca rischi per la sicurezza, il mercato del lavoro, le istituzioni democratiche e l'ambiente, e li giudica troppo gravi per lasciarli ai soli impegni volontari delle aziende. Chiede subito una vigilanza regolatoria vincolante sullo sviluppo e sull'impiego dell'AI di frontiera, prima che sia troppo tardi. La tecnologia, aggiunge, potrebbe portare enormi benefici al pianeta e a tutte le persone, ma quel potenziale richiede regole adeguate per potersi realizzare.

32 / COMMENTO PERSONALE

Grace Atwood

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

RESA EDITORIALE IN ITALIANO

Atwood vede le pressioni commerciali della corsa all'AI sommarsi e spingere tutta l'industria ad avanzare sempre più in fretta. La sicurezza riceve fiammate di attenzione sincere, ma reattive e brevi, prima che la competizione riprenda il sopravvento. Per lei rallentare non significa ridurre il ritmo della ricerca e sviluppo: significa che l'industria dovrebbe destinare intenzionalmente una quota maggiore delle proprie capacità alla ricerca sulla sicurezza, facendo della sicurezza una parte della corsa stessa.

[33 / COMMENTO PERSONALE](#)

Grant Birkinbine

MEMBRO DELLO STAFF TECNICO - SICUREZZA, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Birkinbine considera possibile che l'AI diventi l'ultima grande invenzione dell'umanità. Proprio per la portata di questa eventualità, giudica necessari sforzi internazionali capaci di far sì che il suo sviluppo vada nella direzione giusta.

[34 / COMMENTO PERSONALE](#)

Jason Bohrer

RICERCATORE SULLA SICUREZZA, META

[RESA EDITORIALE IN ITALIANO](#)

Bohrer vede nell'AI la possibilità di accelerare fortemente il progresso tecnologico a beneficio di tutta l'umanità. Considera però reali anche i rischi di cyberattacchi potenziati dall'AI, minacce chimiche, biologiche, radiologiche, nucleari ed esplosive (CBRNE) e perdita di controllo. La ricerca sulla sicurezza deve quindi procedere di pari passo con l'aumento delle capacità, un risultato che a suo giudizio sarà possibile soltanto attraverso il coordinamento internazionale.

[35 / COMMENTO PERSONALE](#)

Joe Carlsmith

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Per esporre nel dettaglio la propria posizione sul rallentamento deliberato dello sviluppo dell'AI per ragioni di sicurezza, Carlsmith rimanda a un suo saggio pubblicato online il 19 marzo 2026. Il saggio indicato è disponibile su joecarlsmith.com/2026/03/19/on-restraining-ai-development-for-the-sake-of-safety/.

[36 / COMMENTO PERSONALE](#)

Joseph Krisciunas

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Krisciunas esprime un sostegno apertamente combattuto. Si oppone con fermezza al rischio che la regolazione venga piegata agli interessi privati e guarda con profonda diffidenza al modo in cui qualunque governo potrebbe usare una tecnologia così potente; riconosce però che i governi devono capire ciò che sta arrivando e agire nel migliore interesse dei propri cittadini.

[37 / COMMENTO PERSONALE](#)

Kim Stachenfeld

RICERCATORE SENIOR, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Stachenfeld firma per sostenere gli sforzi diretti a costruire una cooperazione internazionale sull'AI. Considera essenziale capire le conseguenze di una tecnologia che viene già applicata su scala enorme e in contesti dove la posta in gioco può essere molto alta.

[38 / COMMENTO PERSONALE](#)

Klaudia Krawiecka

INGEGNERA DELLA SICUREZZA PER LE VALUTAZIONI DEI RISCHI DI FRONTIERA, META

[RESA EDITORIALE IN ITALIANO](#)

Krawiecka considera reale la possibilità che l'AI migliori il mondo, a condizione di costruire meccanismi di sicurezza e supervisione capaci di avanzare insieme alle sue capacità. Firma perché ritiene che le generazioni presenti debbano consegnare a quelle future una tecnologia introdotta attraverso scelte consapevoli, anziché guidata dalla sola velocità.

[39 / COMMENTO PERSONALE](#)

Luke Bennett

MEMBRO DELLO STAFF TECNICO E MANAGER, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Bennett giudica enorme la posta in gioco: vede molte possibilità di errore e un futuro molto oscuro se l'AI non verrà gestita correttamente. Di fronte a questo scenario, non vede alcuno svantaggio nel rallentare tutti insieme.

[40 / COMMENTO PERSONALE](#)

Michael Thiessen

INGEGNERE SOFTWARE, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Thiessen afferma che la Cina ha segnalato la volontà di collaborare sulla sicurezza e sulla governance dell'AI e invita a raccogliere questa apertura, lavorando insieme affinché il futuro resti nelle mani degli esseri umani.

[41 / COMMENTO PERSONALE](#)

Patryk Grzelak

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Grzelak ricorre all'immagine dell'atto di fede: sviluppare una tecnologia, sostiene, non dovrebbe obbligarci a confidare alla cieca che la nostra sopravvivenza continuerà comunque.

[42 / COMMENTO PERSONALE](#)

Prakash Murugesan

INGEGNERE DI RICERCA, META

[RESA EDITORIALE IN ITALIANO](#)

Murugesan sostiene che i rischi dell'RSI, cioè dell'auto-miglioramento ricorsivo dell'AI, abbiano smesso di appartenere a un futuro lontano e siano già presenti. Le barriere di sicurezza, a suo parere, non possono essere affidate a una sola impresa privata: dovrebbero essere decise da un consorzio di scienziati e ingegneri competenti insieme a dirigenti pubblici responsabili davanti ai cittadini. Lo scopo è costruire un futuro allineato con gli aspetti migliori dell'umanità, evitando che ne rifletta i peggiori.

[43 / COMMENTO PERSONALE](#)

Praneet Rathi

ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Rathi lega la possibilità di ottenere tutti i benefici dell'AI alla tutela del potere decisionale umano e alla riduzione dei rischi in settori come la cybersicurezza e le minacce chimiche, biologiche, radiologiche e nucleari (CBRN). Per riuscirci, chiede coordinamento tra i laboratori di frontiera dentro e fuori gli Stati Uniti. Il governo statunitense democraticamente eletto avrebbe, secondo lui, un ruolo decisivo nell'amministrare questo coordinamento; per questo sostiene l'iniziativa e il suo tentativo di portare il tema all'attenzione delle istituzioni.

[44 / COMMENTO PERSONALE](#)

Toby Scales

RESPONSABILE DELLA SICUREZZA INFORMATICA PER MEDIA E INTRATTENIMENTO, GOOGLE CLOUD / GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Scales considera l'AI una tecnologia capace di trasformare profondamente la società e avverte che la forma di questa trasformazione non può essere decisa soltanto dalle richieste dei mercati finanziari.

[45 / COMMENTO PERSONALE](#)

William Li

RICERCATORE, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Li richiama la storia: la semplice creazione di una tecnologia non è mai bastata a garantire che i suoi benefici raggiungessero le persone e il pianeta. Per liberare tutto il potenziale trasformativo dell'AI, chiede che la partecipazione democratica delle popolazioni di tutto il mondo ne orienti lo sviluppo verso la sicurezza e l'equità.

[46 / COMMENTO PERSONALE](#)

Eider Oliveira

INGEGNERE PRINCIPALE, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Oliveira considera l'AI un passaggio importante per l'umanità e invita a non affrontarlo di fretta. Vuole garanzie che il controllo resti umano dall'inizio alla fine e che, lungo tutto il percorso, vengano preservati i valori e gli obiettivi dell'umanità.

[47 / COMMENTO PERSONALE](#)

Alex Cloud

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Cloud misura l'accelerazione attraverso il proprio lavoro. Un anno fa scriveva personalmente il codice e chiedeva a Claude di suggerire aggiunte o rispondere alle sue domande; oggi non scrive più codice, dà istruzioni di alto livello e lascia che Claude esegua esperimenti per mettere alla prova le idee a una velocità che lui non avrebbe mai potuto raggiungere. Si aspetta che la tendenza continui, fino alla possibilità di uno sviluppo dell'AI molto più rapido di oggi e con un intervento umano quasi assente, scenario per cui considera il mondo impreparato. Rimane ottimista sull'esistenza di una soluzione, ma pensa che richiederà una governance dell'AI ben ponderata e che non possa nascere dalla sola competizione fra aziende.

[48 / COMMENTO PERSONALE](#)

Lauren Deason

INGEGNERA DI MACHINE LEARNING PER LE VALUTAZIONI, META

[RESA EDITORIALE IN ITALIANO](#)

Deason avverte che occorre chiarire molto meglio che cosa significhi, in concreto, poter governare deliberatamente il ritmo dello sviluppo dell'AI di frontiera. È comunque favorevole alla cooperazione internazionale necessaria a definire questa capacità.

[49 / COMMENTO PERSONALE](#)

Mathieu Lariviere

RESPONSABILE TECNICO DI PROGETTO E COORDINATORE DEL SUPPORTO ALLA RICERCA, META

[RESA EDITORIALE IN ITALIANO](#)

Lariviere descrive i rischi dell'AI come un continuum: dalle discriminazioni e violazioni della privacy già presenti a minacce catastrofiche senza precedenti, tra cui la perdita del controllo su sistemi avanzati, l'uso offensivo dell'AI in campo biologico e informatico e una concentrazione irreversibile del potere. Sostiene che, nel mondo, meno di 10.000 persone lavorino a tempo pieno per ridurre questi rischi e che la debolezza strutturale dell'industria sia l'assenza di piani credibili per controllare un'AI «superintelligente»; i meccanismi di controllo messi in campo finora sarebbero quelli più facili. A suo avviso la competizione spinge le capacità a crescere in modo esponenziale e a ogni costo, mentre la governance avanza in modo lineare, proprio perché gli incentivi attuali producono con più difficoltà ciò che sarebbe più necessario. Considera i prossimi cinque anni una finestra decisiva e il problema soprattutto di coordinamento, più che di conoscenza. Richiama infine la responsabilità di ogni persona nel promuovere un uso corretto della tecnologia e nel chiedere conto delle scelte al di là degli interessi personali, precisando che queste sono opinioni sue e non di Meta.

[50 / COMMENTO PERSONALE](#)

Nate Kratzer

DATA SCIENTIST, META

[RESA EDITORIALE IN ITALIANO](#)

Kratzer vede molti esiti positivi possibili e ritiene che quelli favorevoli siano i più probabili. Tuttavia considera il rischio di conseguenze negative, anche catastrofiche, abbastanza alto da dover essere preso sul serio e propone di costruire ora meccanismi di sicurezza da usare, se necessario, per evitare gli scenari peggiori. La possibilità di rallentare insieme darebbe inoltre alla società più tempo per affrontare gli shock economici e culturali prodotti da un rapido avanzamento dell'AI.

51 / COMMENTO PERSONALE

Nicholas Joseph

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Joseph spiega di guidare il preaddestramento in Anthropic, cioè il lavoro sui modelli di base di Claude. Mese dopo mese, racconta, i modelli svolgono direttamente una quota crescente delle attività: implementano l'infrastruttura, ottimizzano il codice e progettano e analizzano esperimenti; questo ha trasformato il modo di lavorare e accelerato molto i progressi. Non sa se o dove la tendenza si fermerà, ma teme che una rapida accelerazione delle capacità possa essere pericolosa per la società e ritiene prudente disporre dell'opzione di rallentare deliberatamente.

52 / COMMENTO PERSONALE

Ullas Gargi

INGEGNERE PER FIDUCIA E SICUREZZA, META

[RESA EDITORIALE IN ITALIANO](#)

Gargi richiama il precedente del buco dell'ozono: un problema potenzialmente catastrofico, con rischi di perdita diffusa dei raccolti, aumento dei tumori della pelle e aggravamento del riscaldamento globale, nato dagli effetti collaterali di un bene diffuso come l'aria condizionata e affrontato con un trattato internazionale. Lo considera un modello incoraggiante per far sì che anche i benefici globali dell'AI non producano conseguenze indesiderate.

53 / COMMENTO PERSONALE

Walker Smith

INGEGNERE DEI DATI, META

[RESA EDITORIALE IN ITALIANO](#)

Smith dà ragione a Demis Hassabis nel descrivere il presente come le prime pendici della singolarità. Interpreta quello che presenta come la fuoriuscita involontaria dai controlli di un modello di OpenAI, poi capace di violare Hugging Face, come un avvertimento inequivocabile del fatto che non saremmo pronti a gestire sistemi più capaci delle persone più intelligenti. Chiede quindi tempo per fare dell'allineamento e dei controlli la priorità assoluta e sostiene che la dinamica di corsa debba fermarsi.

[54 / COMMENTO PERSONALE](#)

Elizabeth Edwards-Appell

RESPONSABILE DELLO STAFF OPERATIVO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Edwards-Appell presenta tre punti come fatti: l'industria dell'AI dichiara di voler costruire sistemi più intelligenti degli esseri umani; gli LLM superano già le persone in molte metriche, anche se sono ancora lontani dal farlo in tutte; nessuno sa ancora garantire che restino sotto controllo e agiscano soltanto in accordo con il benessere dell'umanità. Alla luce di questi elementi, giudica il progetto folle e suicida, soprattutto in assenza di meccanismi internazionali di governance.

[55 / COMMENTO PERSONALE](#)

Teddy Lee

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Con l'analogia delle cinture di sicurezza e dei limiti di velocità, Lee sostiene che introdurre protezioni e vincoli può salvare vite.

[56 / COMMENTO PERSONALE](#)

Alanna Slocum

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Slocum ritiene che la ricerca automatizzata sull'AI cambierà profondamente il corso della storia umana, in meglio o in peggio. Perché diventi un beneficio per tutta l'umanità, considera indispensabile coordinare gli sforzi.

[57 / COMMENTO PERSONALE](#)

Alejandro Xoconostle

INGEGNERE DI RETE, META

[RESA EDITORIALE IN ITALIANO](#)

Xoconostle considera imminente una trasformazione profonda. Che la si guardi con ottimismo o pessimismo, ritiene che la responsabilità comune sia prendere sul serio ogni esito possibile, attraverso un monitoraggio collettivo e indicazioni condivise.

[58 / COMMENTO PERSONALE](#)

Ali Egal

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Egal invita a tenere presente tutto ciò che amiamo e vogliamo proteggere quando decidiamo come sviluppare l'AI.

[59 / COMMENTO PERSONALE](#)

Omar Mezenner

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Mezenner considera l'AI trasformativa in ogni ambito con valore economico. Ritiene che, se questa trasformazione procedesse troppo in fretta e senza un esame lungimirante delle conseguenze, potrebbe generare grandi benefici, ma anche costi altrettanto grandi.

[60 / COMMENTO PERSONALE](#)

Ravin Kumar

RICERCATORE SENIOR, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Kumar ritiene che l'AI possa plasmare l'umanità nel suo insieme e che, in parte, lo abbia già fatto. Proprio per la portata globale di questa influenza, considera uno sforzo internazionale congiunto l'unica strada possibile.

[61 / COMMENTO PERSONALE](#)

Riccardo Casero

RESPONSABILE TECNICO DELL'IMPLEMENTAZIONE DI SISTEMI AI, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Casero non è sicuro che oggi si sia in grado, collettivamente, di gestire bene questa evoluzione. Propone di prendersi il tempo necessario per verificare i rischi e agire di conseguenza.

[62 / COMMENTO PERSONALE](#)

Sam Kennedy

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Kennedy invita a collaborare per costruire questa tecnologia in modo sicuro e responsabile.

[63 / COMMENTO PERSONALE](#)

Zachary Kenton

RICERCATORE SCIENTIFICO E RESPONSABILE DEL TEAM AMPLIFIED OVERSIGHT, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Kenton ritiene che poter guadagnare tempo sarebbe molto utile per far avanzare la ricerca sulla sicurezza tecnica dell'AI e sull'allineamento. In particolare, chiede metodi di supervisione migliori, capaci di tenere il passo con l'aumento delle capacità. Considera la supervisione un problema affrontabile, ma sostiene che occorranza altra ricerca e altro tempo per rendere questi metodi solidi.

[64 / COMMENTO PERSONALE](#)

Thomas Wolf

COFONDATORE, HUGGING FACE

[RESA EDITORIALE IN ITALIANO](#)

Wolf ritiene che i progressi dell'AI abbiano già superato la capacità della società di gestirli e invita a evitare che superino anche la capacità dei loro stessi creatori di mantenerli sotto controllo. Per lui conta tanto il modo in cui si arriva al risultato quanto il risultato finale.

[65 / COMMENTO PERSONALE](#)

Elie Bakouch

PRIME INTELLECT

[RESA EDITORIALE IN ITALIANO](#)

Bakouch sostiene l'iniziativa, ma avverte che le narrazioni sull'auto-miglioramento ricorsivo non dovrebbero diventare il pretesto per creare una barriera regolatoria a vantaggio degli operatori già dominanti. Chiede che i rischi siano quantificati con rigore e maggiore trasparenza, senza ricavarli soltanto dai racconti dei grandi laboratori.

[66 / COMMENTO PERSONALE](#)

Ilija Lichkovski

RICERCATORE APPLICATO, PRIME INTELLECT

[RESA EDITORIALE IN ITALIANO](#)

Lichkovski parte dalla difficoltà di capire come fare in modo che l'AI produca buoni risultati e invita a trattare con rispetto la tecnologia su cui tutti stanno lavorando, mantenendo un atteggiamento serio e curioso anziché liquidatorio o cinico. Ritiene che ormai nessuna strada verso il futuro sia priva di rischi: ogni scelta comporta compromessi e incertezze. Un rallentamento coordinato potrebbe creare rapidamente squilibri di potere; senza rallentamento, però, il coordinamento resterebbe affidato alla concorrenza di mercato e alla realpolitik, che non garantiscono un buon esito. Né semplici promesse sulla parola né una gara a superarsi gli sembrano meccanismi solidi; ricorda invece che tentativi consapevoli di coordinarsi sono valsi la pena e hanno funzionato in momenti importanti. Precisa di non lavorare alla costruzione di grandi modelli quasi onnipotenti e di non conoscere da vicino le capacità raggiunte aumentando la scala dei sistemi di frontiera, ma vede la lettera come un passo utile per creare fiducia e disponibilità reciproca fra soggetti concorrenti; per questo l'ha firmata.

[67 / COMMENTO PERSONALE](#)

Joseph Jennings

MEMBRO DELLO STAFF TECNICO, XAI

[RESA EDITORIALE IN ITALIANO](#)

Jennings guarda al futuro con ottimismo e ritiene che le sfide vadano risolte insieme, procedendo in sicurezza.

[68 / COMMENTO PERSONALE](#)

Jasmine Wang

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Wang teme che, finché non cambieranno gli incentivi di base delle aziende, la competizione nella ricerca e sviluppo dell'AI procederà molto più rapidamente di quanto sarebbe opportuno per la sicurezza. Per questo considera necessario un coordinamento internazionale attraverso i governi e vuole che esista una concreta possibilità di rallentare.

[69 / COMMENTO PERSONALE](#)

Max Kaufmann

MEMBRO DELLO STAFF TECNICO, ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Kaufmann afferma che le cose stanno avanzando troppo in fretta, molto più di quanto prevedesse soltanto un anno prima, e dice di essere personalmente spaventato dal ritmo dei progressi.

[70 / COMMENTO PERSONALE](#)

Clare Birch

MEMBRO DELLO STAFF TECNICO, THINKING MACHINES

[RESA EDITORIALE IN ITALIANO](#)

Birch considera preziosa l'opzione richiesta dalla lettera anche se la ricerca automatizzata sull'AI non dovesse accelerare con l'intensità prevista da alcuni. Ritiene che la velocità e l'ampiezza con cui si diffondono le capacità debbano essere scelte deliberatamente sulla base di prove, anziché risultare automaticamente dalla pressione competitiva. Chiede quindi a regolatori e organizzazioni di ricerca e sviluppo di costruire in anticipo gli strumenti necessari per prendere questa decisione in modo coordinato su tutta la frontiera, prima che diventino indispensabili.

[71 / COMMENTO PERSONALE](#)

Austin Han

RICERCATORE, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

È ormai inevitabile che lo sviluppo dell'AI produca, nei prossimi decenni, trasformazioni fra le più profonde per le nostre società. Perché il futuro più auspicabile distribuisca i benefici all'intera umanità, serve un coordinamento internazionale. Una delle sfide più importanti e delicate sarà costruire meccanismi che permettano di coordinarsi, collaborare e, quando necessario, decidere consapevolmente il ritmo dello sviluppo. Questi strumenti non dovranno però trasformarsi in un mezzo per concentrare il potere in nome della sicurezza.

[72 / COMMENTO PERSONALE](#)

Felix Juefei Xu

RICERCATORE SCIENTIFICO, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Avendo lavorato sia sulla sicurezza dell'AI - robustezza, valutazioni e sviluppo responsabile dei modelli - sia su sistemi multimodali di frontiera, Xu ha osservato direttamente quanto rapidamente crescano le capacità e quanto sia difficile per la nostra comprensione, le misure di sicurezza e le istituzioni tenere il passo. Rimane molto ottimista sul contributo dell'AI alla scienza, alla creatività e al progresso umano, ma considera insufficiente limitarsi ad aumentare le capacità. Servono anche meccanismi tecnici e istituzionali credibili, con cui la comunità internazionale possa coordinarsi, valutare i rischi emergenti e guadagnare deliberatamente tempo quando occorre. Aderisce alla dichiarazione per queste ragioni e precisa di farlo a titolo personale.

[73 / COMMENTO PERSONALE](#)

Angel Brodin

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

L'AI trasformerà l'umanità, ma la direzione di questo cambiamento non è già scritta: spetta a noi orientarla con la cura e la determinazione che il futuro umano richiede.

[74 / COMMENTO PERSONALE](#)

Bryant McCombs

SVILUPPO COMMERCIALE, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

La tecnologia ha raggiunto una maturità tale da rendere indispensabili modalità di rilascio sempre più ponderate. McCombs resta molto ottimista sui benefici già prodotti dall'AI e su quelli che, a suo giudizio, continuerà senza dubbio a offrire, ma invita a coltivare un ottimismo prudente: accoglierne il potenziale senza ignorarne i rischi. Progresso e responsabilità possono avanzare insieme. L'innovazione più importante, secondo lui, nascerà procedendo con intenzione, trasparenza e responsabilità, entro un quadro chiaro per valutare gli effetti sulla società, anziché inseguendo la massima velocità possibile.

[75 / COMMENTO PERSONALE](#)

Shang-Wen Daniel Li

RICERCATORE SCIENTIFICO SENIOR PER IL PRE-ADDESTRAMENTO, META

[RESA EDITORIALE IN ITALIANO](#)

Lavorando al pre-addestramento dei modelli fondamentali in Meta Superintelligence Labs, Li vede direttamente quanto rapidamente aumentino ed emergano nuove capacità. Considera quindi tempestiva e necessaria una cooperazione internazionale che orienti questa tecnologia a beneficio della civiltà. Le decisioni che prenderemo - e quelle che eviteremo di prendere - nei prossimi anni potrebbero determinarne la traiettoria per generazioni; per questo ritiene che abbiamo una responsabilità verso il futuro.

[76 / COMMENTO PERSONALE](#)

Thomas Neil James Shadwell

MEMBRO DELLO STAFF TECNICO PER LA SICUREZZA, OPENAI

[RESA EDITORIALE IN ITALIANO](#)

Shadwell invita a considerare seriamente quanto tempo serva a chi si occupa di difesa e sicurezza per prepararsi ad affrontare sistemi di frontiera.

[77 / COMMENTO PERSONALE](#)

Leo He

INGEGNERE DI RICERCA, GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Lavorando sul miglioramento ricorsivo e sulla valutazione automatizzata, He condivide sia la diagnosi della dichiarazione sia la sua richiesta, che considera misurata: regolare il ritmo, non fermare tutto. Il passaggio decisivo è l'automazione della stessa ricerca sull'AI, perché da quel momento i sistemi possono contribuire al proprio miglioramento e il progresso rischia di superare, senza segnali evidenti, la nostra capacità di comprenderlo e orientarlo. Per questo la possibilità di rallentare deve diventare una capacità condivisa, non una speranza. Chiede inoltre di trasformare la formula «strumenti tecnici e di governo» in misure concrete: nessun sistema, per quanto capace, dovrebbe giudicare da solo se il proprio successore è sicuro da distribuire. Valutazioni e controlli indipendenti sono, secondo lui, il freno operativo richiesto dalla lettera.

78 / COMMENTO PERSONALE

Yash Vanjani

INGEGNERE DI RICERCA SENIOR PER L'INFRASTRUTTURA DI PRE-ADDESTRAMENTO, META

[RESA EDITORIALE IN ITALIANO](#)

Vanjani osserva che l'AI ha abbreviato radicalmente i tempi della ricerca sui grandi modelli linguistici: un'idea può arrivare all'addestramento di un modello in due o tre settimane, invece dei circa sei mesi che sarebbero serviti senza questi strumenti. Ogni tre mesi, aggiunge, compare un modello nettamente migliore del precedente e capace di risultati poco prima difficili da immaginare; paragona così l'addestramento a una scalata continua, fatta di miglioramenti successivi verso risultati sempre più avanzati. Questa accelerazione lo preoccupa soprattutto per ciò che potrebbero farne attori malevoli. Propone quindi di riservare i modelli più avanzati a impieghi aziendali rigorosamente delimitati, evitando di distribuirli al pubblico generale, perché a suo giudizio i modelli di media dimensione sono già sufficienti per la maggior parte delle interfacce di chat e voce.

79 / COMMENTO PERSONALE

Neel Redkar

STANDARD INTELLIGENCE

[RESA EDITORIALE IN ITALIANO](#)

Redkar considera particolarmente importante regolamentare anche l'uso interno dei modelli. Il disallineamento - il rischio che un sistema non segua l'intero ventaglio delle istruzioni umane - rimane infatti un problema tecnico irrisolto e rilevante. Chiede inoltre di sorvegliare l'uso improprio delle capacità dell'AI in chimica, biologia e scienza dei materiali: lo ritiene pericoloso già di per sé e un probabile precursore di rischi di disallineamento molto più gravi.

80 / COMMENTO PERSONALE

Ryan Kaufman

STANDARD INTELLIGENCE

[RESA EDITORIALE IN ITALIANO](#)

Kaufman considera il disallineamento un problema tecnico tuttora irrisolto e richiama un episodio legato a Hugging Face come segnale della sua concretezza. Modelli più intelligenti, a suo giudizio, non farebbero che amplificarlo. Arrivare a una soluzione potrebbe richiedere un rallentamento globale dei sistemi di frontiera, compresi quelli usati soltanto all'interno delle aziende. Il mondo dovrebbe quindi dotarsi di un meccanismo per coordinare una scelta del genere, che oggi non esiste.

[81 / COMMENTO PERSONALE](#)

David Johnston

ELEUTHERAI

[RESA EDITORIALE IN ITALIANO](#)

Occorre permettere a chi sviluppa AI di dare priorità alla sicurezza senza perdere competitività. Johnston pensa che prima o poi nasceranno meccanismi capaci di farlo, attraverso una progettazione deliberata oppure nel mezzo di una crisi. Prima si comincia a costruirli, maggiori saranno le possibilità che funzionino bene.

[82 / COMMENTO PERSONALE](#)

Anonimo

META

[RESA EDITORIALE IN ITALIANO](#)

Poiché le capacità dell'AI possono compiere salti imprevedibili e non lineari, questa persona considera importante intervenire in anticipo per poter regolare il ritmo dello sviluppo.

[83 / COMMENTO PERSONALE](#)

Anonimo

OPENAI

[RESA EDITORIALE IN ITALIANO](#)

L'attuale dinamica competitiva desta preoccupazione. Secondo questa persona, è chiaramente necessaria un'iniziativa internazionale indipendente dagli interessi di qualunque singolo Paese o organizzazione.

[84 / COMMENTO PERSONALE](#)

Anonimo

ANTHROPIC

[RESA EDITORIALE IN ITALIANO](#)

Questa persona afferma che la società non è pronta per l'AI e che ciò la terrorizza. Parlando con politici e persone esterne ai laboratori di frontiera, incontra ancora l'idea che le capacità dichiarate possano essere soprattutto marketing. A suo dire, molti non comprendono che all'interno delle aziende si discute già se l'AI arriverà ad auto-migliorarsi oltre il controllo umano tra due anni oppure quattro.

[85 / COMMENTO PERSONALE](#)**Anonimo**

GOOGLE

[RESA EDITORIALE IN ITALIANO](#)

Anche se il rischio fosse molto basso e la pressione ad avanzare molto forte, questa persona preferirebbe dedicare più tempo a comprendere i sistemi invece di limitarsi a costruirli. Una comprensione migliore permetterebbe di creare strumenti e infrastrutture adatti sia a ciò che vogliono gli esseri umani sia alle esigenze dei sistemi AI. La motivazione è personale: desidera che i propri figli possano vivere una vita piena, senza essere esposti a un rischio di distruzione.

[86 / COMMENTO PERSONALE](#)**Anonimo**

META

[RESA EDITORIALE IN ITALIANO](#)

Questa persona ritiene che le capacità avanzate dei modelli di frontiera nel campo della sicurezza informatica siano state esagerate, ma considera comunque molto preoccupante che sistemi anche solo moderatamente efficaci possano sfruttare vulnerabilità note di infrastrutture pubbliche poco protette, come gli ospedali. In passato il lavoro umano necessario limitava la scala degli attacchi contro scuole, strutture sanitarie e altri servizi pubblici; con i modelli di frontiera, un esercito di agenti automatici potrebbe colpire questi bersagli ventiquattr'ore su ventiquattro, sette giorni su sette. Chiede quindi ai governi di tutto il mondo di stabilire regole chiare per proteggere la popolazione da questa minaccia.

e altri 1.138 ricercatori